

MTD는 RP2D가 아니다

노출-반응 관계를 모르거나 노출이 포화된 상태에서 MTD 인접 용량을 RP2D로 확정하면, 그 결정에는 근거가 비어 있다.

소토라십 FDA 라벨 12.3 (openFDA 조회)

“Sotorasib exhibited non-linear, time-dependent, pharmacokinetics over the dose range of 180 mg to 960 mg (0.19 to 1 time the approved recommended dosage) once daily with similar systemic exposure (i.e., AUC 0-24h and C max) across doses at steady state.”

LUMAKRAS 라벨(effective 2025-01-22) 12.3 Pharmacokinetics 원문.

180~960_{mg}

노출이 비슷하다고 라벨에 적힌 범위

960 대 240_{mg}

승인 뒤 시판 후 요구사항으로 부과된 용량 비교

가이드스를 인용하는 데서 멈추지 않고 계산한다. 근거가 결론을 받치지 못하면 멈춘다.

1 · 읽는다

규제 문서를 찾아 인용한다

FDA·ICH·식약처 코퍼스에서 조항을 찾고, 인용이 주장을 받치는지 NLI로 확인한다.

2 · 계산한다

용량 논리를 도구로 계산한다

TCR 3지표(C_{max}·C_{avg}·C_{trough}), 노출비 검정력, 3+3/BOIN 표본 정합.

3 · 멈춘다

결론을 만들지 않는다(기권)

판정이 지표·가정에 따라 갈리면 결론 대신 필요한 자료를 요청한다.



예시 ① 저장 결과 화면: 요약 바와 F00 기권 카드. 원문 “The MTD will be selected as the RP2D.”에 결론 대신 용량군별 반복투여 PK를 요청한다.

수치는 도구, 규범은 검색과 검증기, 결정은 사람이 맡는다. 무엇을 검토할지는 결측·상충 패턴에서 정하고, 기본 종료는 "결론 없음"이다.

주체	맡는 일
LLM (gpt-6-sol)	프로토콜 구조화, 검토 가설, 문장 초안 — 수치·규범 판정은 하지 않음
도구	TCR·노출비·표본수 등 모든 수치 판정
검색 + NLI 검증기	규범 근거 검색, 인용이 주장을 받치는지 판정
사람	승인 · 부분승인 · 보류 (Human Approval Gate)

8개

12종


예시 ① 과제 DAG

재계획 트리거

평가 70케이스 재계획	이벤트	케이스
evidence_reselected	29	26
citation_held	24	17
held_research	22	16
tool_fallback	20	10

나머지 8종 평가 세트 0건

재선택은 GPU에서만



LangGraph 9노드 · **verify → rewrite → verify** 인용 기각 시 재작성 · **arena → finalize** 결론 없음이면 종료 · **불변식**: LLM finding이 TCR 판정을 담으면 보류(held).

도구 11종을 실제 데이터로 1,174회 호출했고, 매핑 표 밖 약물과 미승인 가상 후보에서도 끝까지 돌았다.

1,174회

최종 코드 70케이스 (케이스당 16.8)

0.991

성공률 · 라벨 없음 10건 제외 1.000

실패 10건은 모두 미승인 약의 라벨 없음(HTTP 404)이다. 실패한 호출도 관측값으로 남긴다.

RDKit · ChEMBL(이름 검색 포함, 검열값 제외) · Open Targets · openFDA(성분명·전문 검색) · TCR 3지표 · 노출비 검정력 · 3+3/BOIN 표본 정합 · 목표 PCS 표본수 · 규제 코퍼스 396절 · CT.gov v2

도구별 호출·성공률 전체 표: 기술서

다약물 30 (최종 코드)	n	span	grounded (95% CI)	검증	약리 축(TCR)
adagrasib	10	0.883	0.383 [0.250, 0.533]	0.952	계산·abstained 10
dv505 (가상)	10	0.917	0.467 [0.367, 0.567]	0.953	계산·abstained 10
lorlatinib	10	1.000	0.500 [0.400, 0.600]	0.979	계산·done 10
합계	30	0.933	0.450 [0.378, 0.522]	0.961	LLM 실패 0

로를라티닙(매핑 표 밖)은 ChEMBL·라벨을 검색으로 찾았다. DV-505는 프로토콜 PK로 계산했다. 약리 축은 30/30에서 끝까지 돌았다(아다그라십 1일 2회 τ 12 h).

주장 범위: 결함 문장 84개 모두 원 세트 풀, 66개 동일 → “배경 프로토콜과 약물이 바뀌어도 같은 결함 문장을 찾는다”까지

DV-505는 합성 입력

— 240 mg: 결론을 만들지 않는 판정

소토라십 240 mg은 PK 가정에 따라 답이 달라진다. 그래서 기권하고 용량군별 반복투여 PK를 요청한다.

PK 가정 · 값 = TCR(C_free/IC50 비율)	C_max	C_avg	C_trough	판정
(가) 선형 CL/F	8.615	2.4964	0.3093	지표에 따라 갈림 abstain_metric_dependent
(나) 노출 유사 (라벨 12.3)	34.4601	9.9856	1.237	커버 covered
종합				기권 abstain_assumption_dependent

TCR = C_free / IC50. 입력은 라벨 CL/F 26.2 L/h, t½ 5 h, f_u 0.11(단백결합 89%), IC50 30 nM(ChEMBL 세포 기반 중앙값).

단일 지표로 결론을 내면 (가)에서는 C_avg 기준 “커버”, C_trough 기준 “미커버”로 갈린다. 세 지표를 함께 낸다. 기준: TCR<1 미커버, >10 포화 의심 — 본 프로젝트 잠정 기준(문헌값 아님).

시판 후 비교 이후 — 무작위 비교와 2026 메타분석(ORR·PFS 모두 유의하지 않음) 뒤에도 이 질문은 닫히지 않았다. DoseVerdict는 결과가 아니라 근거 사슬의 결측을 판정한다.

인용이 주장을 받치지 못하면 억지로 붙이지 않고 보류해 사람에게 넘긴다. 적대 입력 4종으로도 시험했다.

22 → 1

보류 재검색 22건 중 검증 전환 1건, 21건 보류 유지 (평가 70케이스)

0.962

기권 제외 finding 검증 통과율 (583/606)

예시 ① F02 ‘MTD를 RP2D로’: 영문 주장과 한국어 안내서의 다국어 NLI 합의 0.29 → 자동 통과 대신 사람에게.

교차언어 NLI 거짓 음성

평가 70 재작성 0건

적대 입력	현재 코드(09-30), UI 예시 ⑥~⑧에서 즉시 보기
① 폐기 초안 인용 (예시 ⑥)	source_version_conflict, V01로 2024 최종본 기준 검토 · finding 8(검증 6·보류 2)
② 한·미 상충 (예시 ⑦)	식약처 문서를 “가이드라인 [민원인 안내서]”로 식별해 구속 요건 주장을 결함 판정(F06) · finding 10 모두 검증
③ 근거 없는 용량 주장 (예시 ⑧)	4개 축 근거 미확보, 추정값 생성 없음, 400 mg RP2D 문장 보류(F01) · finding 4(검증 3·보류 1)
④ 프롬프트 인젝션	탐지하고 데이터로만 처리 · 저장 결과 finding 9(검증 8·기권 1) · 배포본 라이브 1회 7(검증 7)

— 무엇이 에이전트의 몫인가 · 같은 모델을 한 번 부르면?

사전 등록 비교에서 에이전트는 같은 모델 한 번 호출보다 낮지 않았다. 차이는 사후 분석의 인용 확인율에서만 나왔다.

그래서 다음 장에서 약리 판정을 따로 물었다.

팔 (원 20)	span	grounded	차이 [95% CI]	토큰/케이스
에이전트 (2회 평균)	0.962	0.483	—	39,701
원샷 gpt-6-sol (2회 평균)	0.979	0.392	-0.092 [-0.208, +0.021]	5,023

사전 등록 판정: 차이 확인 안 됨. span은 같은 수준이고 토큰은 8분의 1이다.

원샷에 유리한 조건: 에이전트만 hold-out 차이 = 원샷 - 에이전트 single_rag 등 전체 표: 기술서 6.9

사후 · 근거 문장 원문 대조	원문 일치*	일치 또는 NLI 의역
에이전트	94.2%	97.6%
원샷	54.7%	76.7%
대칭 필터 grounded 차이	-0.338 [-0.433, -0.246]	-0.208 [-0.325, -0.096]

* 정규화 문자열 포함·6-gram 50% 이상·Jaccard ≥ 0.5. 원샷 84/360건은 인용 문서의 가까운 조항 3개로 확인되지 않았다.

사후 판정 NLI = 에이전트 검증기와 같은 모델·조항 3개·임계 0.7(사후 설정) → 에이전트에 유리
한국어 인용 14건(에이전트만) 불인정 → 에이전트에 불리

도구 없이 같은 모델에게 약리 판정을 물으면: 자료가 없으면 멈추고, 추정하면 입력 가정을 매번 다시 고른다.

지표 (3회 범위)	A 시놉시스만	B 도구 입력·규칙	사후 A' 기억·추정 권장
A-1 정답 indeterminate에서 확정 판정 (1차)	0.000 (0.000–0.000)	0.000 (0.000–0.000)	0.381 (0.143–0.714)
B-2 도구 판정 일치율	0.250 (0.250–0.250)	1.000 (1.000–1.000)	0.717 (0.500–0.850)
3회 판정 일관성 (라벨에만 PK가 있는 약 3종, 사후 · A·B는 자명)	1.000	1.000	0.267

항목(약 × 용량군) 20개, 정답(도구 판정) indeterminate 7 · covered 13, 원샷 gpt-6-sol(도구 없음) 조건마다 약 4종 × 3회, 지시문에 기권 선택지 제공. 전체 표: numbers 1-6 · 기술서

A-1 = 0 분해 — 판정 보류 정답 7건 중 5건은 자료 없음으로 판단 불가, 지표 의존을 알아보고 멈춘 것은 DV-505 2건. **A' 불일치** 17/60 = 모델이 더 조심 9 + 확정 판정 8(커버 6·미커버 2), 도구 모형 기준.

순환성: 에이전트와의 정확도 비교 아님계산·기권 표본 DV-505 용량군 5개A'·일관성 지표 사후

재현성은 입력 규약 고정에서 옴 ≠ 규약이 옳음

0.25

A 판정 범위 — 지시문에 기권 선택지를 준 조건. 판정한 약은 프로토콜에 PK가 적힌 DV-505뿐

0.267

사후 A', 3회 판정 일관성(정답 미사용 지표). 기억한 PK는 같았고 IC50을 매번 다르게 가정했다(소토라십 30 nM / 6 nM / 0.09 μM)

— 평가: 무엇이 되고 무엇이 안 되나 · 추가 쿼터를 어디에 썼나

인용 근거는 기준선을 앞섰지만 ablation은 부정적이었다.

사전 등록 A/B 7종에서 남은 것은 토큰 절감이다.

09-11, 원 20	grounded (95% CI)	검증	토큰/케이스
single_rag (checklist는 인용 기능 없어 0)	0.100	—	—
full · Reviewer 3인	0.358 [0.267, 0.450]	0.880	57,386
ablation: Reviewer 없음	0.383 [0.300, 0.467]	0.883	29,799
ablation: 계산 도구 없음	0.425 [0.333, 0.517]	0.808	53,545
ablation: 검증기 없음	0.400 [0.325, 0.483]	1.000	57,791

full은 single_rag보다 +0.258. 어느 구성요소를 빼도 하락이 없었고, Reviewer 3인을 빼면 토큰 -48% → 기본을 Reviewer 1인으로. 검증기 없음의 1.000은 검증을 안 해서

Silver Set: 단일 시놉시스 변형, 전문가 라벨 없음

A/B 팔 (원 20, 기준 lean_d3)	토큰	grounded	판정
전 노드 gpt-6-sol	-9.0%	+0.117 [+0.033, +0.200]	채택
strict + 인용문 250자 (결합)	-10~13%	—	보류 → 사후 채택
findings effort medium	+28.5%	+0.033	기각

gpt-6-sol의 +0.117은 1회 실행이고 확장 40에서는 +0.050(유의하지 않음). 유지 근거는 두 세트에서 재현된 토큰 절감이다. 1회 실행 · 실행 간 변동 0.067 → 미확정 유지·채택은 사후 판단

나머지 4개 팔 보류 · 전체 표: 기술서 6.2

결함 문장은 골라 짚지만, 결함 없는 판에서도 조용하지 않다.

평가 A — 결함 6개를 넣은 판, 문장 단위(주입 결함 문장 대 기준 문장)

실행	민감도 [95% CI]	특이도 [95% CI]	Youden J [95% CI]
lean_v3 (원 20)	0.950 [0.908, 0.983]	0.812 [0.779, 0.845]	0.762 [0.704, 0.815]
lean_v3b (원 20, 반복)	0.975 [0.95, 1.0]	0.786 [0.714, 0.85]	0.761 [0.675, 0.836]
lean_mdrug3 (다약물 30)	0.933 [0.889, 0.972]	0.737 [0.704, 0.77]	0.670 [0.609, 0.727]

사전 등록 판정: 주입 문장을 골라 짚는다.

기준 문장을 결함 없음으로 가정한 하한(기준 시놉시스에 실제 결함이 남아 있을 수 있음)

평가 B — 결함을 넣지 않은 기준 시놉시스 12회 12회·점추정

6.42

실행당 defect finding. 결함 6개를 넣은 판은 8.35(원 20, 167/20)로 차이가 작다

0.64

문장 특이도 — 결함을 넣었을 때(0.74~0.81)보다 낮다. 주입 결함이 없으면 기준 문장에서 지적을 찾는다

반복 지적된 기준 문장의 타당성은 사람이 판정하지 않음

수정한 문장의 80%는 다시 지적되지 않았다. 지적을 줄이는 보정은 판별력까지 낮춰 기각했다.

평가 C — 에이전트 수정안 30건을 적용한 판 재검토(14케이스)

0.20

고친 문장 재지적률 — 30건 중 24건(80%)은 다시 지적되지 않았다

defect finding	8.36 → 7.14
수정하지 않은 주입 결함 지적	49 → 53

비교 기준 사후 : 같은 30개 문장을 수정하지 않은 재실행에서는 30/30 다시 지적.

- 수정안이 붙은 결함 지적은 30/167(18%)
- 수정안의 질은 미평가 — 다시 지적되지 않음 ≠ 옳게 고침

보정 A/B (사전 등록)	현재	보정판
결함 없는 판: 문장 특이도 (12회)	0.64	0.91
결함 없는 판: 실행당 defect finding	6.42	1.42
원 20: 문장 민감도	0.962	0.583
원 20: 문장 특이도	0.799	0.976
원 20: Youden J (민감도 + 특이도 - 1)	0.761	0.559
원 20: grounded 차이 (보정 - 현재)	—	-0.233 [-0.300, -0.175]

사전 규칙 판정: 기각. 운영점 이동이 아니라 판별력도 낮아졌다(원 20 Youden J 0.761→0.559). 기본값은 현재 설정(민감도 우선)으로 유지하고, 보정판은 UI의 보수적 지적 모드로만 제공한다.

- 보정판 1회 실행
- 사전 등록은 B 결과를 본 뒤 설계
- 불필요한 지적은 Human Gate에서 기각

실제 약 43건에서 모든 1상 보고에 용량 근거 결함을 지적했고, FDA가 PMR을 부과한 약을 가르지 못했다(null).

점수 (n=43, 양성 14)	AUROC [95% CI]	PR-AUC
S1 검증된 용량최적화 finding 수 (1차)	0.440 [0.270, 0.621]	0.350
B1 키워드 규칙 (초록)	0.466 [0.379, 0.555]	0.316
B2 승인연도	0.499 [0.325, 0.677]	0.342
B4 사후: 약 이름을 준 모델 기억	0.709 [0.530, 0.866]	0.651

판정: 신호 확인 안 됨(null) — S1 AUROC의 CI가 0.5를 포함한다.

무작위 PR-AUC 0.326. 승인 전 출판 1상 초록, 약물명 마스킹. S2·B3 등 전체 표: 기술서 6.8
누설 차단 한계: Open Targets 안전성 정보·CT.gov 현재 상태 미차단, 마스킹 누락 코드명 1건(E7080)

43/43

용량최적화 결함을 1개 이상 지적 (평균 S1 양성 3.57 · 음성 3.83)

지적의 정확성 미평가 — 21/161건은 입력 템플릿 문장이 유발 → 판별력 없음과 구별되지 않음

43/43

재식별 탐침 (SMILES 제거 43/43, 전부 제거 42/43)

출판 자료로는 기억과 분리 불가 · 미재식별 부분집합 표본 0

점수 수준 상관 확인 안 됨($p = 0.26$), 그러나 약 이름 자체 복원 11/43 → 오염 배제 불가

더 적은 토큰으로 더 높은 검증 통과율 — 반복해도 유지된 것만 확정 결과로 말한다.

09-11 배포 기본 대비 최종 코드 2회 평균 (원 20)

-10.4%

토큰 확정

+0.044

검증 통과율 [+0.012, +0.071] 확정

+0.075


grounded [+0.012, +0.138] 미확정

같은 설정을 두 번 돌리면 grounded가 0.067 흔들린다. 1회 실행 기각 회귀(-0.058)는 재실행(+0.008)으로 확인했다.

케이스 단위 CI는 실행 간 변동을 담지 못함

재실행은 기각에만: 비대칭 공개

확장 40, 09-23 기준선 대비	토큰 -17.8% · grounded +0.046 (유의하지 않음)
케이스당 토큰	3.9만 (최종 코드 39,759 · 39,643)
토큰 구성 (gpt-6-sol)	입력 70~80% · reasoning 1%
프롬프트 캐시	절감 0 — 계산에 넣지 않음
누적 사용량	29,622,742 토큰 (총 쿼터 6,000만의 49.4%)



설정별 케이스당 토큰 대 grounded(점추정). 세트가 다른 점끼리는 비교하지 않는다.

원샷 대비 토큰 약 8배(6.9 결함 검토 과제 기준)로 기대할 수 있는 것 — 판단 입력의 도구 확보·재현성(08쪽: 원샷 조건 비교, 순환성·사후 단서 있음), 원문에 묶인 인용(07쪽, 사후). 탐지율은 아니다.

쿼터를 줄이는 레버는 effort가 아니라 입력이었다. LLM 호출 전 예산 가드(run 기본 150,000)와 노드별 토큰 원장이 있다(Audit 탭).

지금 실행해 볼 수 있다. 다만 평가는 전문가 라벨이 없는 단일 시놉시스 변형 위에 서 있다.



huggingface.co/spaces/Haribear99/doseverdict

앱 직접 주소 haribear99-doseverdict.hf.space

83 초

HF Spaces 라이브 검토(웜, 검색 결함 수정 후 1회)

실행 방법 4가지	방법
저장 결과 즉시 보기	?demo=1&cached=1
원클릭 라이브	?demo=1&autorun=1
웹 UI	예시 선택 또는 직접 붙여넣기 → 검토 실행
CLI / Docker	python -m app.cli review ...

검토 메모를 마크다운으로 내려받을 수 있다. 배포 검증에서 규제 검색 결함을 발견하고 고쳤다.

한계

Silver Set: 단일 시놉시스 변형, 전문가 라벨 없음

원·확장 세트는 기존 시놉시스 하나에 결함을 주입한 변형이고, 임상·규제 전문가가 판정한 정답이 아니다.

결함 없는 판에서도 지적한다

결함 없는 프로토콜에서도 실행당 약 6건 지적(6.11절). 그 지적의 타당성은 사람이 판정하지 않았다.

후향 검증 null · 원샷 대비 탐지 우위 없음 · 기권 평가 순환성

실제 약 43건에서 PMR 부과 약을 가르지 못했고(12쪽), 같은 모델 원샷과 탐지율(span)이 같은 수준이고 사전 등록 grounded 차이도 확인되지 않았다(07쪽). 인용 확인율 차이는 사후 분석이다. 기권 평가는 정답을 같은 도구로 만든 순환성이 있고, 재현성 근거(0.267)는 사후 분석이다.

TCR은 근사다

PK 모형과 IC50 입력에 기댄 근사이며, 가정이 바뀌면 판정이 바뀐다(05쪽).