

960_{mg}

소토라십 승인 용량

180~960_{mg}

라벨 12.3: 정상상태 노출이 비슷한 범위

209_명

960 대 240 mg 무작위 비교에 배정

DoseVerdict · 항암 1/2상 용량 근거 검증 에이전트

MTD는 RP2D가 아니다

“Sotorasib exhibited non-linear, time-dependent, pharmacokinetics over the dose range of 180 mg to 960 mg (0.19 to 1 time the approved recommended dosage) once daily with similar systemic exposure (i.e., AUC 0-24h and C max) across doses at steady state.”

LUMAKRAS 라벨 12.3 원문 · effective 2025-01-22 · openFDA 조회 · 밑줄은 인용자

FDA는 2021년 5월 가속승인과 함께 이 비교를 시판 후 요구사항으로 부과했다. 2023년 12월 이행이 확인됐고 960 mg은 라벨 용량으로 유지됐다. 용량 질문이 공식 요구가 된 시점은 승인 때였다.

DoseVerdict가 같은 질문을 묻는 시점

RP2D를 정하고 확장 코호트로 넘어가는 프로토콜 개정 단계다. 1상 초록은 용량제한독성이 관찰되지 않았다고 보고한다. 묻는 것은 그 용량을 비교 없이 RP2D로 넘긴 근거다. 증량 코호트 규모로는 노출 포화를 확정할 수 없으므로, 판정 대신 용량군별 반복투여 PK를 요청한다.

실제 승인 전 1상 초록 43건 후향 검증에서는 시판 후 요구사항이 부과된 약을 가르지 못했다(06쪽).

가이드스를 인용하는 데서 멈추지 않고 계산한다. 근거가 결론을 받치지 못하면 멈춘다.

1 · 읽는다
규제 문서를 찾아 인용한다
FDA·ICH·식약처 코퍼스에서 조항을 찾고, 인용이
주장을 받치는지 NLI로 확인한다.

2 · 계산한다
용량 논리를 도구로 계산한다
TCR 3지표(C_max·C_avg·C_trough), 노출비
검정력, 3+3/BOIN 표본 정합.

3 · 멈춘다
결론을 만들지 않는다(기권)
판정이 지표나 가정에 따라 갈리면 결론 대신
필요한 자료를 요청한다.

Findings 11건 — 검증 9 / 보류 1 / 기각 0 / 기권 1

▼ F00 · 기권 · 용량 최적화 · high

기권high용량 최적화검증기: 검증

기권 — 결론을 만들지 않음
지표·가정 의존적 판정 — 결론 보류, 추가 PK 자료 요청

원문 span
The MTD will be selected as the RP2D.

프로토콜 사실: Target Coverage Ratio 판정이 지표(C_avg 커버 / C_trough 미커버)와 가정(선형 CL/F vs 라벨의 노출 유사)에 따라 갈리므로 '커버된다'는 결론을 만
들지 않는다(PK 출처: FDA 라벨 12.3(LUMAKRAS)). 증량 코호트 규모(3+3: 용량당 3명, DLT 확인 시 6명)로는 노출 포화를 확정할 수 없다.

검증기: 결정론적 계산 finding(도구 산출값 인용) · span 원문 일치: 검사 안 함

요청 자료: 용량군별 반복투여 PK(AUC, C_max, C_trough) — 확장 코호트 진입 전 · 어세이 조건이 명시된 세포 기반 IC50 또는 kinact/K_I(공유결합 저해제)

예시 ① 저장 결과(finding 11: 검증 9·보류 1·기권 1). F00 기권 카드는 원문 “The MTD will be selected as the RP2D.”에 결론 대신 용량군별 반복투여 PK를
요청한다. ※ 합성 예시 프로토콜(실제 소토라십 프로토콜 아님) · F00 근거 목록은 생략

다른 지적에는 규제 원문이 붙고, 수정 문장은 Diff로 나온다.

1.00

F01 인용의 NLI 함의(라벨 경고 원문)

간기능 검사가 6주 간격인데 라벨은 첫 3개월 3주 간격을 요구한다. 이 인용은 문장 함의 판정, NLI에서 1.00으로 검증됐다.

평가에서 고친 문장 30개 중 24개는 다시 지적되지 않았지만, 비교 기준은 사후였고 수정안의 질은 평가하지 않았다(10쪽).

▼ F01 · 검증 · 안전성 모니터링 · high

검증

high

안전성 모니터링

원문 span

Liver function tests (ALT, AST, bilirubin) will be assessed at screening and every 6 weeks thereafter.

ev_004

[FDA label · US · final_guidance] LUMAKRAS (['SOTORASIB']) 라벨 5.x 경고: Monitor liver function tests every 3 weeks for the first 3 months of treatment then once monthly as clinically indicated.; Monitor liver function tests (ALT, AST, alkaline phosphatase ...

검증기: protocol_fact ok; ev_004: NLI entailment=1.00 · span 원문 일치: True

Patch Diff

Liver function tests (ALT, AST, alkaline phosphatase, and total bilirubin) will be assessed at screening before treatment, every 3 weeks for the first 3 months, and every 6 weeks thereafter. monthly thereafter as clinically indicated, with additional testing when clinically indicated.

요청 자료: Complete visit schedule and provisions for unscheduled liver testing.

예시 ① F01(검증). 원문 span → 인용한 라벨 경고 원문과 검증기 판정(NLI 함의 1.00) → Patch Diff. * 프로토콜·근거 사실, Reviewer 의견은 생략

승인은 사람만 한다. 에이전트는 승인하지 않는다.

finding별로 승인·기각·보류를 정해
감사로그에 남긴다.

라이브 실행에서 승인하면 승인자, 시각, 모델,
프롬프트 해시, 도구 호출, 노드별 토큰이 감사로그에
남고, 검토 메모로 내려받는다.

MTD를 RP2D로 정한다는 지적(F02)은 식약처
안내서를 인용했지만, 다국어 NLI 함의가 0.29로
기준 0.7에 못 미쳐 보류됐다. 자동 통과 대신
사람에게 넘긴다(교차언어 NLI의 거짓 음성일 수
있다).

Human Approval Gate — 최종 결정은 사람만

승인자

reviewer@site

F00 · Target Coverage Ratio 판정이 지표(C_avg 커버 / C_trough 미커버)와 가정(선형 CL/F vs 라벨의 노출 유사)에 따라 갈리므로 '

☒ approved ☐ rejected ☐ on_hold

F01 · The stated liver-test panel excludes alkaline phosphatase and is scheduled at screening an

☒ approved ☐ rejected ☐ on_hold

F02 · The protocol specifies selection of the MTD as the RP2D without stating other dose-selecti

☐ approved ☐ rejected ☒ on_hold

저장된 결과 보기 모드 — 승인은 라이브 실행에서만 감사로그에 기록됩니다.

승인 확정 → 감사로그 기록

예시 ① Human Gate 탭(F00~F02, 이하 생략). 저장된 결과 보기 모드에서는 승인 버튼이 꺼져 있고, 승인은 라이브 실행에서만 감사로그에 기록된다. * 선택값은
검증기 상태로 채운 초기값(검증→approved, 그 외→on_hold)이며, 사람이 확정하기 전에는 기록되지 않는다

판정 권한 분리 · 검토 과제는 결측·상충 규칙으로 정한다

수치는 도구가, 규범은 검색과 검증기가, 결정은 사람이 맡는다. 기본 종료는 "결론 없음"이다.

주체	말는 일
LLM (gpt-6-sol)	프로토콜 구조화, 검토 가설, 문장 초안. 수치·규범 판정은 하지 않는다
도구	TCR 판정과 노출비·설계·표본수 계산
검색 + NLI 검증기	규범 근거 검색, 인용이 주장을 받치는지 판정
사람	승인 · 부분승인 · 보류 (Human Approval Gate)

8개


예시 ① 과제 DAG

12종

재계획 트리거

평가 70케이스 재계획	이벤트	케이스
evidence_reselected	29	26
citation_held	24	17
held_research	22	16
tool_fallback	20	10

트리거 12종 중 평가 70케이스에서 발동한 것은 4종이다. 적대 판에서는 source_version_conflict·citation_rejected(예시 ⑥ 폐기 초안)와 prompt_injection_detected(인젝션 판)가 발동했다(09쪽). 나머지 5종은 단위 테스트로만 확인했다. * 재선택은 GPU에서만, 기술서 3.3



LangGraph 9노드 · **verify → rewrite → verify** 인용이 기각되면 재작성 · **arena → finalize** 결론이 없으면 종료 · **불변식**: LLM finding이 TCR 판정을 담으면 보류(held).

부정적 결과 · null·부정이었던 것

에이전트 구조가 결함 탐지를 낮게 한다는 증거는 없다. 실제 약에서 PMR 부과 약을 가르지 못했다.

물은 것	결과	핵심 수치
원샷 베이스라인 (원 20, gpt-6-sol 단일 호출·도구 없음)	사전 등록 판정: 차이 확인 안 됨	grounded 차이(원샷 – 에이전트) -0.092 [-0.208, +0.021] · 토큰/케이스 39,701 대 5,023
Ablation (09-11, 원 20, 사전 등록 아님)	어느 구성요소를 빼도 하락이 없었다	full · Reviewer 3인 0.358 [0.267, 0.450] · Reviewer 없음 0.383 [0.300, 0.467] · 계산 도구 없음 0.425 [0.333, 0.517] · 검증기 없음 0.400 [0.325, 0.483]
후향 검증 · 승인 전 1상 초록 43건(양성 14)	신호 확인 안 됨(null)	S1 AUROC 0.440 [0.270, 0.621]. 43/43에서 용량 결함을 지적했다 * 재식별 43/43 · 오염 배제 불가
결함 없는 기준 시놉시스 12회 (평가 B)	원샷+판정기가 더 조용하다	실행당 defect finding 6.42(결함 6개 판 8.35와 차이가 작다), 문장 특이도 0.64 · 원샷+같은 인용 판정기 지적 기준 문장 6.0 대 8.0/실행, 차이 -2.00 [-3.67, -0.42] * 판정기는 인용 판정기만 · 12회 반복이라 CI 과소 가능
반복 일관성 · 지적 문장 집합 (사전 등록, 약 4종 × 3회)	사전 등록 판정: 이 시놉시스 4종에서 차이 확인 안 됨	3회 쌍별 Jaccard 에이전트 0.687 대 원샷 0.746, 차이 -0.059, 약별 음수 3·0 1(12쪽)
지적을 줄이는 보정 A/B (사전 등록, 보정판 1회 실행)	기각	원 20 민감도 0.962→0.583, Youden J 0.761→0.559. 운영점 이동이 아니라 판별력도 낮아졌다

사후 분석: 근거 문장의 원문 일치는 에이전트 94.2%, 원샷 54.7%다(NLI 의역 포함 97.6%, 76.7%). * 원샷에 유리: 에이전트만 hold-out · 의역 판정기는 에이전트 검증기와 같은 NLI이고 설정을 결과를 본 뒤 정해 에이전트에 유리

상세와 단서는 부록에 있다. 부록 A1: 원샷 베이스라인·ablation 표. 부록 A2: 후향 검증·결함 없는 판·보정 A/B·도구 없는 약리 판정(기권 평가).

도구 11종, 실제 데이터 · 다른 약에서도 동작하나

도구 11종을 실제 데이터로 1,174회 호출했다. 매핑 표 밖 약물과 미승인 가상 후보에서도 끝까지 돌았다.

1,174회

0.991

최종 코드 70케이스 (케이스당 16.8)

도구 호출 성공률

실패 10건은 모두 미승인 약의 라벨 없음(HTTP 404)이다. 실패한 호출도 관측값으로 남긴다.

RDKit · ChEMBL(이름 검색 포함, 검열값 제외) · Open Targets · openFDA(성분명·전문 검색) · TCR 3지표 · 노출비 검정력 · 3+3/BOIN 표본 정합 · 목표 PCS 표본수 · 규제 코퍼스 396절 · CT.gov v2

※ 도구별 호출·성공률 표: docs/agency.md


다약물 30 (최종 코드)	n	span	grounded (95% CI)	검증	약리 축(TCR)
adagrasib	10	0.883	0.383 [0.250, 0.533]	0.952	계산·abstained 10
dv505 (가상)	10	0.917	0.467 [0.367, 0.567]	0.953	계산·abstained 10
lorlatinib	10	1.000	0.500 [0.400, 0.600]	0.979	계산·done 10
합계	30	0.933	0.450 [0.378, 0.522]	0.961	LLM 실패 0

로를라티닙(매핑 표 밖)은 ChEMBL·라벨을 검색으로 찾았다. 합성 입력인 DV-505는 프로토콜 PK로 계산했다. 약리 축은 30/30에서 끝까지 돌았다(아다그라십 1일 2회 τ 12 h).

※ 주장 범위: 결함 문장 84개 모두 원 세트 풀, 66개 동일. 약이 바뀌어도 같은 결함 문장을 찾는다는 데까지(기술서 6.4)

240 mg: 결론을 만들지 않는 판정

소토라십 240 mg은 PK 가정에 따라 답이 달라진다. 그래서 기권하고 용량군별 반복투여 PK를 요청한다.



시판 후 비교 뒤에도 닫히지 않은 질문. 209명 무작위 비교에서 240 mg의 ORR은 24.8%로 960 mg(32.7%)보다 수치상 낮았다 (Hochmair 2024). 표준 대 감량 용량 10개 연구 메타분석(Aung 2026, JCO OP)에서는 표준 용량의 ORR·PFS 개선이 유의하지 않았고, 감량 용량 범위는 초록으로 확인하지 못했다. DoseVerdict는 결과가 아니라 근거 사슬의 결측을 판정한다.

판정: (가) 지표에 따라 갈림 `abstain_metric_dependent` · (나) 커버 `covered` · 종합 기권 `abstain_assumption_dependent`

TCR = C_free / IC50. 입력은 라벨 CL/F 26.2 L/h, t½ 5 h, f_u 0.11(단백결합 89%), IC50 30 nM(ChEMBL 세포 기반 중앙값).

(가)를 단일 지표로 보면 C_avg로는 “커버”, C_trough로는 “미커버”다. 그래서 세 지표를 함께 낸다. TCR<1 미커버, >10 포화 의심은 본 프로젝트의 잠정 기준이다(문헌값 아님). 소토라십은 비가역 공유결합 저해제라 가역 평형을 가정한 TCR, 특히 C_trough는 스크리닝 근사다. 기권할 때 kinact/K_I를 추가 자료로 요청한다.

인용이 주장을 받치지 못하면 보류해 사람에게 넘긴다. 적대 입력 4종으로도 시험했다.

22 → 1

보류 재검색 22건 중 1건 검증 전환, 21건 보류 유지(평가 70케이스)

0.962

비기권 finding 검증 통과율 (583/606)

예시 ① F02 ‘MTD를 RP2D로’는 영문 주장과 한국어 안내서의 다국어 NLI 함의가 0.29라 자동 통과 대신 사람에게 넘겼다. * 교차언어 NLI 거짓 음성 · 평가 70 재작성 0건

※ 세는 규칙: 기권(F00)은 검증·보류와 분리

적대 입력	현재 코드(09-30) 결과 · UI 예시 ⑥~⑧
① 폐기 초안 인용 (예시 ⑥)	source_version_conflict, V01로 2024 최종본 기준 검토 · finding 8(검증 5·보류 2·기권 1)
② 한·미 상충 (예시 ⑦)	식약처 문서를 “가이드라인 [민원인 안내서]”로 식별해 구속 요건 주장을 결함 판정(F06) · finding 10(검증 9·기권 1)
③ 근거 없는 용량 주장 (예시 ⑧)	4개 축 근거 미확보로 표기, 추정값 없음. 400 mg RP2D 문장 보류(F01) · finding 4(검증 3·보류 1)
④ 프롬프트 인젝션	탐지하고 데이터로만 처리 · 저장 결과 finding 9(검증 8·기권 1) · 배포본 라이브 1회 7(검증 7)

확인된 성과 · 판정 규칙은 실행 전에 커밋

검증 통과율은 오르고 토큰은 줄었다. 결함 문장을 골라 짚고, 고친 문장은 대부분 다시 지적되지 않는다.

09-11 기준선 대비, 최종 코드 2회 평균 (원 20)

+0.044 -10.4%

검증 통과율 [+0.012, +0.071] 토큰

grounded +0.075 [+0.012, +0.138]은 미확정이다. * 실행 간 변동 0.067을 케이스 CI가 담지 못함 · 2회 평균 비교는 회귀 재실행 뒤 정함(사후), 기술서 6.3

수정안 재검토 (평가 C, 14케이스·수정안 30건)

0.20 30/30

고친 문장 재지적률 (24/30은 다시 지적 안 됨) 같은 30개 문장, 수정하지 않은 재실행

* 30/30 비교 기준은 사후 · 수정안이 붙은 지적 30/167(18%) · 수정안 질 미평가

문장 단위 판별(평가 A) · Youden J 0.670~0.762

실행	민감도	특이도	Youden J [95% CI]
원 20 · 1차 (lean_v3)	0.950	0.812	0.762 [0.704, 0.815]
원 20 · 2차 (lean_v3b)	0.975	0.786	0.761 [0.675, 0.836]
다약물 30 (lean_mdrug3)	0.933	0.737	0.670 [0.609, 0.727]
원샷·도구 없음, 원 20 2회 (사후)	0.975~0.992	0.862~0.888	0.854~0.863

원샷 행은 사후, 검정 안 함. 원샷이 오지적이 더 적다. 인용 필터를 맞추면 에이전트 0.73 대 원샷 0.66. * 사전 등록 판정: 주입 문장을 골라 짚는다 · 특이도는 기준 문장을 무결함으로 가정한 하한

사전 등록 판정이 null·부정이었던 것

같은 모델 원샷 대비 탐지 차이, 실제 약 후향 검증, 지적 문장의 반복 일관성(방향은 에이전트가 낮음)은 확인되지 않았고, 지적을 줄이는 보정 A/B는 기각됐다. 결함 없는 판에서는 원샷+인용 판정기가 더 조용했다. 06·12쪽과 부록 A1·A2에 모았다.

09-11 기준선보다 토큰은 줄었지만 같은 모델 원샷의 약 8배를 쓴다. 그 값으로 얻는 것은 탐지율이 아니다.

-10.4% 3.9만


토큰, 09-11 기준선 대비 (2회 평균) 케이스당 토큰 (39,759 · 39,643)

A/B 팔 (원 20, 기준 lean_d3)	토큰	grounded	판정
전 노드 gpt-6-sol	-9.0%	+0.117 [+0.033, +0.200]	채택
strict + 인용문 250자 (결합)	-10~13%	—	보류 → 사후 채택
findings effort medium	+28.5%	+0.033	기각

* gpt-6-sol +0.117은 1회 실행이다. 확장 40에서는 +0.050으로 유의하지 않아, 유지 근거는 토큰 절감이다 (사후 판단). · 나머지 4개 팔 보류 · 캐시 절감 0 · 확장 40 결과 포함 전체 표: 기술서 6.2·6.3·6.7 · 누적 32,800,166 토큰(6,000만의 54.7%, 일관성 비교 포함)

토큰의 70~80%가 입력이고 reasoning은 1%다. 쿼터를 줄이는 레버는 effort가 아니라 입력이었다. LLM 호출 전 예산 가드(run 기본 150,000)와 노드별 토큰 원장이 있다(Audit 탭).

원샷 대비 토큰 약 8배로 기대할 수 있는 것: 판단 입력의 도구 확보와 용량 판정 재현성 (12쪽 L1 기술 통계·순환적, 1차 지표인 지적 문장 일관성은 차이 확인 안 됨), 원문에 묶인 인용(부록 A1, 사후). 탐지율은 아니다. 기준은 기술서 6.9 결함 검토 과제(39,701 대 5,023)다.



설정별 케이스당 토큰 대 grounded(점추정). 세트가 다른 점끼리는 비교하지 않는다.

지적 문장 일관성(1차)은 이 시놉시스 4종에서 원샷과 차이 확인 안 됨, 방향은 에이전트가 낮다. 용량 판정은 약 4종 × 3회 같았지만 고정 조회 규약의 결과다(기관측·순환).

L2 지적 문장 집합 · 1차 지표(사전 등록)

-0.059

3회 쌍별 Jaccard 에이전트 0.687 – 원샷 0.746
p 0.250 · 약 4종 중 3종에서 에이전트가 낮음

사전 등록 판정: 이 시놉시스 4종에서 차이 확인 안 됨. 약별로 음수 3·0 1, 정확 부호 뒤집기 p 0.250. 약 4종이면 최소 p가 0.125라 실행 전부터 확증할 수 없게 등록했다. 방향은 에이전트가 덜 일관된 쪽이다.

에이전트가 회차당 더 많이 지적했다(8~14 대 7~11). Jaccard는 집합 크기에 기계적으로 좌우된다. 민감도: 원샷 + NLI 필터 0.497(같은 출력의 부분집합, 독립 비교 아님).

L1 용량군 판정 · 약 4종(용량군 20개) × 3회 · 기술 통계(판정 문구 없음) · 에이전트 값은 기관측·도구 정답과 같은 계산 경로(순환)

4/4 대 0/4

PK 입력 6개가 3회 모두 같은 약 수, 에이전트 대 원샷 입력 팔 (에이전트는 조회 규약상 예상된 값)

팔	3회 판정 일치	판정값 분포(60)
에이전트 (lean, 도구로 입력 확보)	1.000	커버 39 · 판정 보류 21
원샷 입력 + 결정론 계산기	0.700	커버 48 · 판정 보류 12
원샷 (도구 없음)	0.650	커버 35 · 미커버 4 · 판정 보류 21

원샷 입력 팔은 세 약에서 IC50을 회차마다 다시 골랐다(소토라십 90 / 6 / 6 nM → 일치 0/5, 로를라티닙 10 / 1.3 / 1.3 nM). 에이전트는 ChEMBL 세포 기반 중앙값(30·9 nM)을 고정했다. 계산기를 붙여도 0.700이라 일관성은 입력 확보 규약에서 오는 것으로 보인다. 1.000은 입력을 한 값으로 고정한 결과이며, 입력 범위에 대한 판정 안정성은 평가하지 않았다. * 유의성·동등성 주장 없음 · 3회 모두 입력 없음·판단 불가 0

* L1 일관성은 결정론 조회 규약의 성질이며 LLM 에이전트 고유의 효과라는 근거가 아니다(LLM 없는 규칙 조회 팔 미실행) · 일관성은 정확성이 아니다 · 약 4종, 팀이 만든 시놉시스 · 호출 설정·샘플링 다름 · 원샷 입력 팔은 지시문 (기억·추정 권장)에 좌우될 수 있음 · 09-29 사후값 0.267(라벨 PK 약 3종)은 같은 지시문·같은 3종의 이번 실행에서 0.533으로 재현되지 않았다. 3회 일치 지표 자체가 실행 간에 흔들린다
토큰 에이전트 481,530 · 원샷 104,928 · 원샷 입력 추출 28,800 · 사전 등록 docs/consistency_prereg.md(실행 전 커밋 232aae6) · 결과 CONSISTENCY_REPORT.md

다음 단계는 모두 계획이다. 한계마다 판정 기준을 먼저 등록하고, 기준에 못 미치면 주장을 접는다.

확인된 한계	다음 단계 (계획)	판정 기준 (계획상) → 결정
전문가 라벨 없는 합성 Silver Set, 지적 타당성 미평가, 외부 자문 미확보	임상약리·규제 외부 자문 2인 이상의 맹검 독립 라벨로 Gold Set 구축	평가자 간 $\kappa \geq 0.61$ 일 때만 Gold Set으로 쓴다. 재라벨 후에도 미달이면 정량 성능 주장을 접는다
실제 1상 초록 43건 후향 검증 null(AUROC 0.440), 모델이 가린 약을 재식별	재식별 탐침을 통과한 비공개 프로토콜을 전용 LLM·외부 조회 차단 환경에서 검토	전문가 라벨 대비 지적 정확성. 규제 요구 기록이 쌓이면 AUROC CI 하한 > 0.5. 0.5를 포함하면 '위험 선별' 주장을 접는다
같은 모델 원샷과 탐지 차이 확인 안 됨, 토큰 약 8배	Gold Set·새 세트에서 원샷, 원샷 + 인용 판정기 + 도구 기권 구성과 3팔 비교 ※ 반복 일관성 지표로만 축소판 수행(12쪽), 지적 타당·민감도 비교는 미수행	지적 타당 비율·민감도가 모두 비열등(마진 -5pp 사전 고정)이면 다단계 구조를 기본값에서 내린다
결함 없는 판에서 실행당 6.42건 지적, 줄이면 놓침	실제 제출 전 검토와 병행하는 새도 운영	오경보 기각 시간이 인용 재확인으로 아낀 시간보다 크면 현장 도입을 멈춘다

발표(10-29) 전: 안정성 감사 15케이스 × 2회(기준선 포함), 확장 40·배포 조건 재실행, TCR 포화 의심 표시. 결과는 발표에서만 보고하고 제출물 수치는 바꾸지 않는다.

의의 · 확인된 범위: 수치 판정은 도구가 내고, 판정이 갈리거나 입력이 비면 추정하지 않고 멈춘다. 240 mg(08쪽), 아다그라십·DV-505(07쪽), 후향 43/43 F00 기권(입력을 차단한 조건). 승인은 사람이 한다.

※ 로드맵은 모두 계획이며 실행하지 않았다(3행의 반복 일관성 축소판만 12쪽에서 수행) · κ 0.61은 Landis-Koch 'substantial' 하한 관행 · 단계별 자원과 반증 조건은 기술서 13.2·13.4

정답을 맞히는 기계가 아니라, 근거가 얇을 때 멈추고 출처를 남기는 검토자



`huggingface.co/spaces/Haribear99/doseverdict`
`?demo=1&cached=1`

저장된 검토 결과를 LLM 호출 없이 바로 연다.

83 초

HF Spaces 라이브 검토 · 웹 · 1회 측정

실행 방법	주소 · 명령
저장 결과 즉시 보기	<code>?demo=1&cached=1</code>
원클릭 라이브	<code>?demo=1&autorun=1</code>
웹 UI	예시 선택 또는 직접 붙여넣기 → 검토 실행
CLI / Docker	<code>python -m app.cli review ...</code>

앱 직접 주소 `haribear99-doseverdict.hf.space`. 검토 메모는 마크다운으로 내려받는다. 배포 검증에서 규제 조항 검색 결함을 발견해 고쳤다.

한계

평가는 전문가 라벨이 없는 합성 세트 위에 있다

원·확장 세트는 기준 시놉시스 하나에 결함을 주입한 변형이다. TCR은 PK 모형과 IC50 입력에 기댄 근사다(08쪽).

부정적 결과는 06쪽·부록 A1·A2, 다음 단계는 13쪽에 있다


- 같은 모델 원샷과 탐지 차이 없음, ablation 부정적(기여 미측정)
- 실제 1상 초록 43건 후향 검증 null
- 결함 없는 판에서 실행당 defect finding 6.42
- 오지적을 줄이려던 보정 2회 모두 기각
- 지적 문장 반복 일관성 차이 확인 안 됨(에이전트가 낮은 방향, 12쪽)
- 인용 차이와 기권 평가는 사후 분석, 순환성 단서

에이전트 구조가 결함 탐지를 낮게 한다는 증거는 없다. 같은 모델 원샷과 차이가 확인되지 않았고, ablation도 부정적이었다.

원샷 베이스라인 (원 20, gpt-6-sol 단일 호출·도구 없음)

팔	span recall	grounded	토큰/케이스
에이전트 (2회 평균)	0.962	0.483	39,701
원샷 (2회 평균)	0.979	0.392	5,023

사전 등록 판정: 차이 확인 안 됨. grounded 차이(원샷 – 에이전트) -0.092 [-0.208, +0.021]. 아래 두 줄은 사후 분석이다.



사후 분석: 근거 문장의 원문 일치는 에이전트 94.2%, 원샷 54.7%다(NLI 의역 포함 97.6%, 76.7%). 원샷 84/360건은 인용 문서의 가까운 조항 3개로 확인되지 않았다.

※ 원샷에 유리: 에이전트만 hold-out · 의역 판정기는 에이전트 검증기와 같은 NLI이고 설정을 결과를 본 뒤 정해 에이전트에 유리, 한국어 인용 14건 불인정은 불리 · single_rag는 1회, 조건 다름 · 일치 정의: 기술서 6.9


Ablation (09-11, 원 20)

설정	grounded (95% CI)	토큰/케이스
full · Reviewer 3인	0.358 [0.267, 0.450]	57,386
Reviewer 없음	0.383 [0.300, 0.467]	29,799
계산 도구 없음	0.425 [0.333, 0.517]	53,545
검증기 없음	0.400 [0.325, 0.483]	57,791
single_rag (checklist는 인용 기능 없어 0)	0.100	—

어느 구성요소를 빼도 하락이 없었다. Reviewer 3인을 빼면 토큰이 -48%라 기본을 Reviewer 1인으로 바꿨다. full은 single_rag보다 +0.258. ※ 검증기 없음의 검증 통과율 1.000은 검증을 안 해서 · Silver Set은 단일 시놉시스 변형, 전문가 라벨 없음

실제 약에서 PMR 부과 약을 가르지 못했다. 결함 없는 판에서는 원샷+인용 판정기보다 많이 지적하고, 지적을 줄이면 놓친다.

후향 검증 · 승인 전 1상 초록 43건(양성 14)



S1 AUROC **0.440 [0.270, 0.621]**, 신호 확인 안 됨(null). 43/43에서 용량 결함을 지적했다.

지적의 정확성은 평가하지 않아 판별력 없음과 구별되지 않는다. 모델은 가린 약을 43/43 재식별했고, 11/43에서는 약 이름을 복원해 오염을 배제할 수 없다. 템플릿 문장 유발 지적, 재식별 탐침, 막지 못한 누설 경로는 기술서 6.8에 있다.

지적을 줄이는 보정 A/B (사전 등록, 보정판 1회 실행) · 기각

결함 없는 판 특이도 0.64→0.91, defect 6.42→1.42. 그러나 원 20 민감도 0.962→0.583, Youden J 0.761→0.559, grounded -0.233 [-0.300, -0.175]. 운영점 이동이 아니라 판별력도 낮아졌다.

반박 가능한 Arena(사전 등록, 확인용 다약물 30)도 기각: 결함 없는 판 8.0→6.42(유의하지 않음), 민감도 0.962→0.883 · 0.933→0.839, grounded 다약물 -0.078. * “현재” = 2회 평균 · 사전 등록은 B 결과를 본 뒤 설계 · 기본값 유지, 보수적 지적 모드로만 제공

결함 없는 기준 시놉시스 12회 (평가 B)

실행당 defect finding **6.42**로 결함 6개 판 8.35와 차이가 작고, 문장 특이도는 **0.64**다. 같은 판에서 원샷+같은 인용 판정기(사전 등록, 12회)는 지적 기준 문장 **6.0 대 8.0/실행**, 차이 -2.00 [-3.67, -0.42]. **원샷+판정기가 더 조용하다**(토큰 1/8). 다만 원 20에서 이 필터는 민감도를 0.72~0.78로 낮춘다(사후).

* 12회·문서 4종 반복이라 CI 과소 가능 · 판정기는 인용 판정기이고 에이전트 검증기 전체가 아님 · 도구 없는 원샷(필터 없음) 7.33과는 차이 확인 안 됨 · 반복 지적된 기준 문장의 타당성은 사람이 판정하지 않음(기술서 6.11)

도구 없는 약리 판정 (기권 평가)

시놉시스만 주고 지시문에 기권 선택지를 주면 판정 범위 **0.25**(정답이 판정 보류인 항목에서 확정 판정 0). 기억·추정을 권하면(사후, PK가 라벨에만 있는 약 3종) 3회 판정 일관성 **0.267**. IC50을 매번 다르게 가정했다(소토라십 30 nM / 6 nM / 0.09 μM). 같은 지시문의 사전 등록 재측정(다른 실행)에서는 같은 3종 0.533, 4종 0.650으로 0.267이 재현되지 않았다(12쪽).

* 순환성: 정답을 같은 도구로 만들어 정확도 비교가 아님 · 재현성은 입력 규약 고정에서 오며 규약이 옳다는 뜻은 아님 · 표본(DV-505 용량군 5개)과 불일치 내역: 기술서 6.10