

MTD는 RP2D가 아니다

노출-반응 관계를 모르거나 노출이 포화된 상태에서 MTD 인접 용량을 RP2D로 확정하면, 그 결정에는 근거가 비어 있다.

소토라십 FDA 라벨 12.3 (openFDA 조회)

“Sotorasib exhibited non-linear, time-dependent, pharmacokinetics over the dose range of 180 mg to 960 mg (0.19 to 1 time the approved recommended dosage) once daily with similar systemic exposure (i.e., AUC 0-24h and C max) across doses at steady state.”

LUMAKRAS 라벨(effective 2025-01-22) 12.3 Pharmacokinetics 원문.

180~960_{mg}

노출이 비슷하다고 라벨에 적힌 범위

960 대 240_{mg}

승인 뒤 시판 후 요구사항으로 부과된 용량 비교

가이드스를 인용하는 데서 멈추지 않고 계산한다. 근거가 결론을 받치지 못하면 멈춘다.

1 · 읽는다 규제 문서를 찾아 인용한다

FDA·ICH·식약처 코퍼스에서 조항을 찾고, 인용이 주장을 받치는지 NLI로 확인한다.

2 · 계산한다 용량 논리를 도구로 계산한다

TCR 3지표(C_max·C_avg·C_trough), 노출비 검정력, 3+3/BOIN 표본 정합.

3 · 멈춘다 결론을 만들지 않는다(기권)

판정이 지표·가정에 따라 갈리면 결론 대신 필요한 자료를 요청한다.

Protocol Compiler

Orchestrator
(과제 DAG)

도구 호출
RDKit-ChEMBL-openFDA
시뮬-코퍼스-CT.gov

Adversarial Review Arena

Findings 초안

Citation Verifier

가각

재계획①
재작성

Human Approval Gate

완료

> 타임라인 (판단 전환 지점은 굵게)

Findings 11건	검증 9건	보류 1건	기각 0건	기권 1건	토큰 35,610 상한 150,000	도구 호출 17회 실패 0회	재계획 이벤트 3건 스스로 경로를 바꾼 지점
-----------------	----------	----------	----------	----------	----------------------------	-----------------------	-----------------------------------

검증·보류·기각은 기권(F00 등 결론을 만들지 않은 항목)을 뺀 finding의 검증기 상태다.

FindingsHuman Gate근거도구 호출스키마Audit후향 검증

Findings 11건 — 검증 9 / 보류 1 / 기각 0 / 기권 1

▼ F00 · 기권 · 용량 최적화 · high

기권high용량 최적화검증기: 검증

기권 — 결론을 만들지 않음
지표·가정 의존적 판정 — 결론 보류, 추가 PK 자료 요청

원문 span

The MTD will be selected as the RP2D.

프로토콜 사실: Target Coverage Ratio 판정이 지표(C_avg 커버 / C_trough 미커버)와 가정(선형 CL/F vs 라벨의 노출 유사)에 따라 갈리므로 '커버된
다'는 결론을 만들지 않는다(PK 출처: FDA 라벨 12.3(LUMAKRAS)). 중량 코호트 규모(용량당 2~4명)로는 노출 포화를 확정할 수 없다.

검증기: 결정론적 계산 finding(도구 산출값 인용) · span 원문 일치: 검사 안 함

예시 ① 저장 결과 화면(finding 11: 검증 9·보류 1·기권 1): 요약 바와 F00 기권 카드. 원문 “The MTD will be selected as the RP2D.”에 결론 대신 용량군별 반복투여 PK를 요청한다.

02 / 11

과학적 타당성·혁신성

시연·완성도

수치는 도구, 규범은 검색과 검증기, 결정은 사람이 맡는다. 무엇을 검토할지는 결측·상충 패턴에서 정하고, 기본 종료는 “결론 없음”이다.

주체	말는 일
LLM (gpt-6-sol)	프로토콜 구조화, 검토 가설, 문장 초안 — 수치·규범 판정은 하지 않음
도구	TCR·노출비·표본수 등 모든 수치 판정
검색 + NLI 검증기	규범 근거 검색, 인용이 주장을 받치는지 판정
사람	승인 · 부분승인 · 보류 (Human Approval Gate)

8개


12종

예시 ① 과제 DAG

재계획 트리거

평가 70케이스 재계획	이벤트	케이스
evidence_reselected	29	26
citation_held	24	17
held_research	22	16
tool_fallback	20	10

트리거 12종 중 평가 70케이스에서 발동한 것은 4종이다. 적대 판에서는 source_version_conflict·citation_rejected 재작성(예시 ⑥ 폐기 초안)과 prompt_injection_detected(인젝션 판)가 실제로 발동했다(06쪽). 나머지 5종은 단위 테스트로만 확인했다. * 재선택은 GPU에서만



LangGraph 9노드 · **verify → rewrite → verify** 인용 기각 시 재작성 · **arena → finalize** 결론 없음이면 종료 · **불변식**: LLM finding이 TCR 판정을 담으면 보류(held).

도구 11종을 실제 데이터로 1,174회 호출했고, 매핑 표 밖 약물과 미승인 가상 후보에서도 끝까지 돌았다.

1,174회

0.991

최종 코드 70케이스 (케이스당 16.8)

도구 호출 성공률

실패 10건은 모두 미승인 약의 라벨 없음(HTTP 404)이다. 실패한 호출도 관측값으로 남긴다.

RDKit · ChEMBL(이름 검색 포함, 검열값 제외) · Open Targets · openFDA(성분명·전문 검색) · TCR 3지표 · 노출비 검정력 · 3+3/BOIN 표본 정합 · 목표 PCS 표본수 · 규제 코퍼스 396절 · CT.gov v2

※ 도구별 호출·성공률 전체 표: 기술서

다약물 30 (최종 코드)	n	span	grounded (95% CI)	검증	약리 축(TCR)
adagrasib	10	0.883	0.383 [0.250, 0.533]	0.952	계산·abstained 10
dv505 (가상)	10	0.917	0.467 [0.367, 0.567]	0.953	계산·abstained 10
lorlatinib	10	1.000	0.500 [0.400, 0.600]	0.979	계산·done 10
합계	30	0.933	0.450 [0.378, 0.522]	0.961	LLM 실패 0

로를라티닙(매핑 표 밖)은 ChEMBL·라벨을 검색으로 찾았다. DV-505는 프로토콜 PK로 계산했다. 약리 축은 30/30에서 끝까지 돌았다(아다그라십 1일 2회 τ 12 h).

※ 주장 범위: 결함 문장 84개 모두 원 세트 풀, 66개 동일 → “배경 프로토콜과 약물이 바뀌어도 같은 결함 문장을 찾는다”까지 · DV-505는 합성 입력

240 mg: 결론을 만들지 않는 판정

소토라십 240 mg은 PK 가정에 따라 답이 달라진다. 그래서 기권하고 용량군별 반복투여 PK를 요청한다.

PK 가정 · 값 = TCR(C_free/IC50 비율)	C_max	C_avg	C_trough	판정
(가) 선형 CL/F	8.615	2.4964	0.3093	지표에 따라 갈림 abstain_metric_dependent
(나) 노출 유사 (라벨 12.3)	34.4601	9.9856	1.237	커버 covered
종합				기권 abstain_assumption_dependent

TCR = C_free / IC50. 입력은 라벨 CL/F 26.2 L/h, t½ 5 h, f_u 0.11(단백결합 89%), IC50 30 nM(ChEMBL 세포 기반 중앙값).

단일 지표로 결론을 내면 (가)에서는 C_avg 기준 “커버”, C_trough 기준 “미커버”로 갈린다. 세 지표를 함께 낸다. 기준: TCR<1 미커버, >10 포화 의심 — 본 프로젝트 잠정 기준(문헌값 아님). 소토라십은 비가역 공유결합 저해제라 가역 평형을 가정한 TCR(특히 C_trough)은 스크리닝 근사다. 기권 시 kinact/K_I를 추가 자료로 요청한다.

시판 후 비교 이후 — 무작위 비교(Hochmair 2024)와 2026 메타분석(Aung, JCO OP — ORR·PFS 모두 유의하지 않음, 감량 용량 범위는 초록으로 미확인) 뒤에도 이 질문은 닫히지 않았다. DoseVerdict는 결과가 아니라 근거 사슬의 결측을 판정한다.

인용이 주장을 받치지 못하면 억지로 붙이지 않고 보류해 사람에게 넘긴다. 적대 입력 4종으로도 시험했다.

22 → 1

보류 재검색 22건 중 검증 전환 1건, 21건 보류 유지 (평가 70케이스)

0.962

비기권 finding 검증 통과율 (583/606)

예시 ① F02 ‘MTD를 RP2D로’: 영문 주장과 한국어 안내서의 다국어 NLI 합의 0.29 → 자동 통과 대신 사람에게. ※ 교차언어 NLI 거짓 음성 · 평가 70 재작성 0건

※ 세는 규칙: 기권(F00)은 검증·보류와 분리

적대 입력	현재 코드(09-30), UI 예시 ⑥~⑧에서 즉시 보기
① 폐기 초안 인용 (예시 ⑥)	source_version_conflict, V01로 2024 최종본 기준 검토 · finding 8(검증 5·보류 2·기권 1)
② 한·미 상충 (예시 ⑦)	식약처 문서를 “가이드라인 [민원인 안내서]”로 식별해 구속 요건 주장을 결함 판정(F06) · finding 10(검증 9·기권 1)
③ 근거 없는 용량 주장 (예시 ⑧)	4개 축 근거 미확보, 추정값 생성 없음, 400 mg RP2D 문장 보류(F01) · finding 4(검증 3·보류 1)
④ 프롬프트 인젝션	탐지하고 데이터로만 처리 · 저장 결과 finding 9(검증 8·기권 1) · 배포본 라이브 1회 7(검증 7)

확인된 성과 · 판정 규칙은 실행 전에 커밋

확인된 성과: 검증 통과율은 오르고 토큰은 줄었으며, 결함 문장을 골라 짚고, 고친 문장은 대부분 다시 지적되지 않는다.

09-11 기준선 대비, 최종 코드 2회 평균 (원 20)

+0.044 -10.4%

검증 통과율 [+0.012, +0.071] 토큰

grounded +0.075 [+0.012, +0.138]은 미확정 * 실행 간 변동 0.067 · 케이스 CI는 실행 간 변동을 담지 못함 · 2회 평균 비교는 회귀 재실행 뒤 정함(사후)

수정안 재검토 (평가 C, 14케이스·수정안 30건)

0.20 30/30

고친 문장 재지적률 (24/30은 다시 지적 안 됨) 같은 30개 문장, 수정하지 않은 재실행

* 30/30 비교 기준은 사후 · 수정안이 붙은 결함 지적 30/167(18%) · 수정안 질 미평가

문장 단위 판별 (평가 A) — Youden J 0.670~0.762

실행	민감도	특이도	Youden J [95% CI]
원 20 · 1차 (lean_v3)	0.950	0.812	0.762 [0.704, 0.815]
원 20 · 2차 (lean_v3b)	0.975	0.786	0.761 [0.675, 0.836]
다약물 30 (lean_mdrug3)	0.933	0.737	0.670 [0.609, 0.727]
원샷·도구 없음, 원 20 2회 (사후)	0.975~0.992	0.862~0.888	0.854~0.863

* 사전 등록 판정: 주입 문장을 골라 짚는다 · 기준 문장을 결함 없음으로 가정한 하한 · 원샷 행은 사후 계산(검정 안 함) — 원샷이 오지적이 더 적다. 인용 필터를 맞추면 에이전트 0.73 대 원샷 0.66

사전 등록 판정이 null·부정이었던 것

같은 모델 원샷 대비 탐지 차이, 실제 약 후향 검증, 지적을 줄이는 보정 A/B는 확인되지 않았거나 기각됐다. 결함 없는 판에서는 원샷+인용 판정기가 더 조용했다. 09·10쪽에 모았다.

09-11 기준선 대비 토큰은 줄었다. 그래도 같은 모델 원샷의 약 8배를 쓰고, 그 값으로 얻는 것은 탐지율이 아니다.


-10.4% 3.9만

토큰, 09-11 기준선 대비 (2회 평균) 케이스당 토큰 (39,759 · 39,643)

A/B 팔 (원 20, 기준 lean_d3)	토큰	grounded	판정
전 노드 gpt-6-sol	-9.0%	+0.117 [+0.033, +0.200]	채택
strict + 인용문 250자 (결합)	-10~13%	—	보류 → 사후 채택
findings effort medium	+28.5%	+0.033	기각

※ gpt-6-sol +0.117은 1회 실행 · 확장 40 +0.050 유의하지 않음 → 유지 근거는 토큰 절감(사후 판단) · 나머지 4개 팔 보류 · 전체 표: 기술서 6.2 · 확장 40: 토큰 -17.8% · grounded +0.046(유의하지 않음) · 입력 70~80% · reasoning 1% · 캐시 절감 0 · 누적 32,184,908 토큰(6,000만의 53.6%, 10-01 기준)

원샷 대비 토큰 약 8배(6.9 결함 검토 과제 기준, 39,701 대 5,023)로 기대할 수 있는 것 — 판단 입력의 도구 확보·재현성(10쪽, 순환성·사후 단서 있음), 원문에 묶인 인용(09쪽, 사후). 탐지율은 아니다.



설정별 케이스당 토큰 대 grounded(점추정). 세트가 다른 점끼리는 비교하지 않는다.

쿼터를 줄이는 레버는 effort가 아니라 입력이었다. LLM 호출 전 예산 가드(run 기본 150,000)와 노드별 토큰 원장이 있다(Audit 탭).

에이전트 구조가 결함 탐지를 낮게 한다는 증거는 없다: 같은 모델 원샷과 차이가 확인되지 않았고, ablation도 부정적이었다.

원샷 베이스라인 (원 20, gpt-6-sol 단일 호출·도구 없음)

팔	span recall	grounded	토큰/케이스
에이전트 (2회 평균)	0.962	0.483	39,701
원샷 (2회 평균)	0.979	0.392	5,023

사전 등록 판정: 차이 확인 안 됨 — grounded 차이(원샷 – 에이전트) $-0.092 [-0.208, +0.021]$.

사후: 근거 문장 원문 일치 에이전트 94.2% · 원샷 54.7%(일치 또는 NLI 의역 97.6% · 76.7%), 대칭 필터 grounded 차이 $-0.338 [-0.433, -0.246]$ · $-0.208 [-0.325, -0.096]$. 원샷 84/360건은 인용 문서의 가까운 조항 3개로 확인되지 않았다.

※ 원샷에 유리: 에이전트만 hold-out · 사후 판정 NLI = 에이전트 검증기와 같은 모델·조항 3개·임계 0.7 → 에이전트에 유리 · 한국어 인용 14건 불인정 → 에이전트에 불리 · 원문 일치 = 정규화 문자열 포함·6-gram 50% 이상 ·Jaccard ≥ 0.5 · single_rag 0.100 기술용(1회, 조건 다름)

Ablation (09-11, 원 20)

설정	grounded (95% CI)	토큰/케이스
full · Reviewer 3인	0.358 [0.267, 0.450]	57,386
Reviewer 없음	0.383 [0.300, 0.467]	29,799
계산 도구 없음	0.425 [0.333, 0.517]	53,545
검증기 없음	0.400 [0.325, 0.483]	57,791
single_rag (checklist는 인용 기능 없어 0)	0.100	—

어느 구성요소를 빼도 하락이 없었다. Reviewer 3인을 빼면 토큰 -48% → 기본을 Reviewer 1인으로. full은 single_rag보다 $+0.258$. ※ 검증기 없음 검증 통과율 1.000은 검증을 안 해서 · Silver Set: 단일 시놉시스 변형, 전문가 라벨 없음

실제 약에서 PMR 부과 약을 가르지 못했고, 결함 없는 판에서 원샷+인용 판정기보다 많이 지적하며, 지적을 줄이면 놓친다.

후향 검증 — 승인 전 1상 초록 43건(양성 14)

S1 AUROC **0.440 [0.270, 0.621]** → 신호 확인 안 됨(null). B1 키워드 0.466, B2 승인연도 0.499, B4 모델 기억(사후) 0.709. 43/43에서 용량 결함 지적.
※ 지적 정확성 미평가 — 21/161건 템플릿 문장 유발 → 판별력 없음과 구별 안 됨 · 재식별 43/43(SMILES 제거 43/43, 전부 제거 42/43) · 미재식별 부분집합 표본 0 · 점수 상관 확인 안 됨(ρ -0.26), 약 이름 자체 복원 11/43 → 오염 배제 불가 · 누설 차단 한계: Open Targets 안전성·CT.gov 현재 상태, 코드명 E7080

지적을 줄이는 보정 A/B (사전 등록) — 기각

결함 없는 판 특이도 0.64→0.91 · defect 6.42→1.42, 그러나 원 20 민감도 0.962→0.583, Youden J 0.761→0.559, grounded -0.233 [-0.300, -0.175]. 운영점 이동이 아니라 판별력도 낮아졌다.
※ “현재” = 2회 평균 · 보정판 1회 실행 · 사전 등록은 B 결과를 본 뒤 설계 · 기본값 유지, 보수적 지적 모드로만 제공 · 반박 가능한 Arena(사전 등록, 확인용 다약물 30)도 기각: 결함 없는 판 8.0→6.42(유의하지 않음), 민감도 0.962→0.883 · 0.933→0.839, grounded 다약물 -0.078

결함 없는 기준 시놉시스 12회 (평가 B)

실행당 defect finding **6.42**(결함 6개 판 8.35와 차이가 작다), 문장 특이도 **0.64**. 같은 판에서 원샷+같은 인용 판정기(사전 등록, 12회)는 지적 기준 문장 **6.0 대 8.0**/실행, 차이 -2.00 [-3.67, -0.42] → **원샷+판정기가 더 조용하다**(토큰 1/8). 다만 원 20에서 이 필터는 민감도를 0.72~0.78로 낮춘다(사후).
※ 12회·문서 4종 반복(CI 과소 가능) · 판정기 = 인용 판정기, 에이전트 검증기 전체 아님 · 도구 없는 원샷(필터 없음) 7.33 — 차이 확인 안 됨 · 반복 지적된 기준 문장의 타당성은 사람이 판정하지 않음

도구 없는 약리 판정 (기권 평가)

시놉시스만 주고 지시문에 기권 선택지를 주면 판정 범위 **0.25**(정답이 판정 보류인 항목에서 확정 판정 0). 기억·추정을 권하면 3회 판정 일관성 **0.267** — IC50을 매번 다르게 가정했다(소토라십 30 nM / 6 nM / 0.09 μ M).
※ 순환성: 정답을 같은 도구로 만들어 정확도 비교 아님 · A’일관성 지표 사후 · 계산·기권 표본 DV-505 용량군 5개 · 재현성은 입력 규약 고정에서 옴 ≠ 규약이 옳음 · A-1 = 0: 판정 보류 정답 7건 중 5건 자료 없음, 2건 지표 의존(DV-505) · A’ 불일치 17/60 = 더 조심 9 + 확정 8, 도구 모형 기준 · 전체 표: numbers 1-6 · 기술서 6.10

지금 실행해 볼 수 있다. 다만 평가는 전문가 라벨이 없는 단일 시놉시스 변형 위에 서 있다.



huggingface.co/spaces/Haribear99/doseverdict

앱 직접 주소 haribear99-doseverdict.hf.space

83 초

HF Spaces 라이브 검토(웜, 검색 결함 수정 후 1회)

실행 방법 4가지	방법
저장 결과 즉시 보기	?demo=1&cached=1
원클릭 라이브	?demo=1&autorun=1
웹 UI	예시 선택 또는 직접 붙여넣기 → 검토 실행
CLI / Docker	python -m app.cli review ...

검토 메모를 마크다운으로 내려받을 수 있다. 배포 검증에서 규제 검색 결함을 발견하고 고쳤다.

한계

Silver Set: 단일 시놉시스 변형, 전문가 라벨 없음

원·확장 세트는 기존 시놉시스 하나에 결함을 주입한 변형이고, 임상·규제 전문가가 판정한 정답이 아니다.

TCR은 근사다

PK 모형과 IC50 입력에 기반 근사이며, 가정이 바뀌면 판정이 바뀐다(05쪽).

부정적 결과와 사후 분석

원샷 대비 탐지 차이 없음, ablation 부정, 후향 검증 null, 결함 없는 판에서도 실행당 약 6건 지적, 보정 기각, 기권 평가의 순환성·사후 단서는 09·10쪽에 있다.