

MTD는 RP2D가 아니다

노출-반응 관계를 모르거나 노출이 포화된 상태에서 MTD 인접 용량을 RP2D로 확정하면, 그 결정에는 근거가 비어 있다.

소토라십 FDA 라벨 12.3 (openFDA 조회)

“Sotorasib exhibited non-linear, time-dependent, pharmacokinetics over the dose range of 180 mg to 960 mg (0.19 to 1 time the approved recommended dosage) once daily with similar systemic exposure (i.e., AUC 0-24h and C max) across doses at steady state.”

LUMAKRAS 라벨(effective 2025-01-22) 12.3 Pharmacokinetics 원문.

180~960_{mg}

노출이 비슷하다고 라벨에 적힌 범위

960 대 240_{mg}

승인 뒤 시판 후 요구사항으로 부과된 용량 비교

가이드스를 인용하는 데서 멈추지 않고, 용량 논리를 계산한다. 근거가 결론을 받치지 못하면 멈춘다.

1 · 읽는다

규제 문서를 찾아 인용한다

FDA·ICH·식약처 코퍼스에서 조항을 검색하고, 인용이 주장을 받치는지 NLI로 확인한다.

2 · 계산한다

용량 논리를 도구로 계산한다

TCR 3지표(C_{max}·C_{avg}·C_{trough}), 노출비 검정력, 3+3/BOIN 표본 정합.

3 · 멈춘다

결론을 만들지 않는다(기권)

판정이 지표·가정에 따라 갈리면 결론 대신 필요한 자료를 요청한다.

▼ F00 · 기권 · 용량 최적화 · high

기권high용량 최적화검증가: 검증

기권 — 결론을 만들지 않음
지표·가정 의존적 판정 — 결론 보류, 추가 PK 자료 요청

원문 span

The MTD will be selected as the RP2D.

프로토콜 사실: Target Coverage Ratio 판정이 지표(C_{avg} 커버 / C_{trough} 미커버)와 가정(선형 CL/F vs 라벨의 노출 유사)에 따라 갈리므로 '커버 된다'는 결론을 만들지 않는다(PK 출처: FDA 라벨 12.3(LUMAKRAS)). 중량 코호트 규모(용량당 2~4명)로는 노출 포화를 확정할 수 없다.

검증가: 결정론적 계산 finding(도구 산출값 인용) · span 원문 일치: 검사 안 함

규제high

The label reports unknown exposure–response relationships and nonlinear, time-dependent PK through 960 mg. Sparse sampling and no planned dose comparison leave the protocol without material to substantiate an exposure–response rationale, particularly for 1200 mg.

ev_008 [DoseVerdict · - · -] TCR(선형 CL/F 가정, PK FDA 라벨 12.3(LUMAKRAS), IC50 30.0 nM — ChEMBL 세포 기반 중앙값, f_u 0.11 — 단백결합 89.0%(FDA 라벨 12.3(LUMAKRAS)), t_½ 5.0 h, τ 24.0 h — 명시 없음 → 1일 1회 가정): 180 mg: C_{max} 6.5/C_{avg} 1.9/C_{trough} 0.23 → abstain_metric_dep...

ev_009 [DoseVerdict · - · -] CL/F CV 76.0%(FDA 라벨 12.3(LUMAKRAS)) 기준 두 용량군 AUC 비 95% CI 폭: n=2 14.109배, n=4 6.499 배, n=12 2.946배. 중량 코호트 규모(2~4명)로는 노출 포화를 확정할 수 없다....

ev_005 [FDA label · US · final_guidance] LUMAKRAS 12.2/12.3: exposure–response relationships and the time course of the pharmacodynamic response are unknown. non-linear, time-dependent, pharmacokinetics over the dose range of 180 mg to 960 mg (0...

요청 자료: 용량군별 반복투여 PK(AUC, C_{max}, C_{trough}) — 확장 코호트 진입 전 · 어세이 조건이 명시된 세포 기반 IC50 또는 kinact/K_J(공유결합 저해제)

예시 ① 저장 결과, F00 기권 카드 — 원문 “The MTD will be selected as the RP2D.”에 대해 결론 대신 용량군별 반복투여 PK를 요청한다.


02 / 16

과학적 타당성·혁신성

구조화·가설·문장은 LLM, 수치는 도구, 규범은 검색과 검증기, 최종 결정은 사람이 맡는다.

주체	맡는 일	맡지 않는 일
LLM (gpt-6-sol)	프로토콜 구조화, 검토 가설, 문장 초안	수치 판정, 규범 판정
도구	TCR·노출비·표본수 등 모든 수치 판정	—
검색 + NLI 검증기	규범 근거 검색, 인용이 주장을 받치는지 판정	—
사람	승인 · 부분승인 · 보류 (Human Approval Gate)	—

LangGraph 9노드



verify → rewrite → verify 인용 기각 시 재작성 루프 **arena → finalize** 결론 없음이면 바로 종료

불변식 — LLM finding이 TCR 판정을 담으면 보류(held)한다. 수치 판정은 도구 finding만 할 수 있다.

— 스스로 정하는 것

무엇을 검토할지는 결측·상충 패턴에서 정하고, 종료 조건의 기본값은 “결론 없음”이다.

예시 ① 과제 DAG 8개 — 필드가 있으면 과제가 생기고, 과제가 도구를 정한다

과제	도구	선행
T01 구조 계열	<code>rdkit.structure_profile</code> · <code>chembl.potency</code>	—
T02 표적 근거	<code>opentargets.target_evidence</code>	—
T03 계열 라벨 대조	<code>openfda.label</code>	T01, T02
T04 노출-용량 관계	<code>pharm.tcr_three_metrics</code> · <code>pharm.exposure_power</code>	T01
T05 설계 운영특성	<code>design.compare_sample_matched</code> · <code>design.required_sample_for_pcs</code>	—
T06 규제 조항 KR	<code>corpus.search</code>	—
T07 규제 조항 US	<code>corpus.search</code>	—
T08 유사시험	<code>ctgov.search_analog_trials</code>	—

필드가 없으면 과제를 만들지 않고 “근거 미확보 측”으로 표기한다.

12종

재계획 트리거 — 대체 조회, 보류 재검색, 호출 전 예산 가드 포함

평가 70케이스에서 실제로 발생한 재계획

트리거	이벤트	케이스
<code>evidence_reselected</code>	29	26
<code>citation_held</code>	24	17
<code>held_research</code>	22	16
<code>tool_fallback</code>	20	10

나머지 8종은 평가 세트에서 0건. 인젝션·폐기 초안은 평가 세트에 없어 데모·적대 테스트로 보인다. `evidence_reselected`는 GPU에서만 켜지며 배포본(CPU)에서는 꺼진다.

도구 11종을 실제 데이터로 1,174회 호출했다. 실패한 호출도 관측값으로 남긴다.

1,174회
최종 코드 70케이스의 도구 호출 (케이스당 16.8)

0.991
성공률. 실패 10건은 모두 미승인 약의 라벨 없음(HTTP 404)

1.000
예상된 라벨 없음 10건을 뺀 성공률 (1,164회)

도구	내용	호출	성공률
pharm.tcr_three_metrics	TCR 3지표	367	1.000
openfda.label	openFDA 라벨(성분명·전문 검색)	167	0.940
corpus.search	규제 코퍼스 396절	140	1.000
rdkit.structure_profile	RDKit 구조 계열	70	1.000
opentargets.target_evidence	Open Targets 표적 근거	70	1.000
pharm.exposure_power	노출비 검정력	70	1.000
design.compare_sample_matched	3+3/BOIN 표본 정합	70	1.000
design.required_sample_for_pcs	목표 PCS 표본수	70	1.000
ctgov.search_analog_trials	CT.gov v2 유사시험	70	1.000
chembl.potency	ChEMBL 효력값(검열값 제외)	60	1.000
chembl.lookup	ChEMBL 이름 검색	20	1.000
합계	도구 종류 11개	1174	0.991

— 다른 약에서도 동작하나

매핑 표 밖 약물과 미승인 가상 후보에서도 끝까지 돌았고, 결과는 원 세트와 비슷했다.

약물(기준 시놉시스)	n	span	grounded (95% CI)	검증	도구 성공/실패	약리 축(TCR)
adagrasib	10	0.883	0.383 [0.250, 0.533]	0.952	150/0	계산·abstained 10
dv505 (가상)	10	0.917	0.467 [0.367, 0.567]	0.953	164/10	계산·abstained 10
lorlatinib	10	1.000	0.500 [0.400, 0.600]	0.979	197/0	계산·done 10
다약물 30 합계	30	0.933	0.450 [0.378, 0.522]	0.961		LLM 실패 0

- 로를라티닙(매핑 표 밖): ChEMBL·라벨을 검색으로 찾았다.
- DV-505(미승인 가상 후보): 프로토콜에 적힌 PK로 계산했다. 도구 실패 10건은 라벨 없음(404)이다. DV-505는 합성 입력이다.
- 약리 축은 30/30에서 끝까지 돌았다(아다그라십 1일 2회 τ 12 h).

주장 범위 — 결함 문장 84개가 모두 원 세트와 같은 풀에서 왔고 66개는 원 세트 주입 문장과 같다. 따라서 주장은 “배경 프로토콜과 약물이 바뀌어도 같은 결함 문장을 찾는다”까지다.



데모 DV-505(가상): 프로토콜 보고 PK로 TCR을 계산하고 기권(F00).

— 240 mg: 결론을 만들지 않는 판정

소토라십 240 mg은 PK 가정에 따라 답이 달라진다. 그래서 기권하고 용량군별 반복투여 PK를 요청한다.

PK 가정	C_max	C_avg	C_trough	판정
(가) 선형 CL/F	8.615	2.4964	0.3093	지표에 따라 갈림 abstain_metric_dependent
(나) 노출 유사 (라벨 12.3)	34.4601	9.9856	1.237	커버 covered
종합				기권 abstain_assumption_dependent

TCR = C_free / IC50. 입력은 라벨 CL/F 26.2 L/h, t½ 5 h, f_u 0.11(단백결합 89%), IC50 30 nM(ChEMBL 세포 기반 중앙값).

단일 지표로 결론을 내면 (가)에서는 C_avg 기준 “커버”, C_trough 기준 “미커버”로 갈린다. 세 지표를 함께 낸다. 기준: TCR<1 미커버, >10 포화 의심 — 본 프로젝트 잠정 기준(문헌값 아님).

시판 후 비교 이후 — 무작위 비교와 2026 메타분석(ORR·PFS 모두 유의하지 않음) 뒤에도 이 질문은 닫히지 않았다. DoseVerdict는 결과가 아니라 근거 사슬의 결측을 판정한다.

인용이 주장을 받치지 못하면 억지로 붙이지 않고, 보류해 사람에게 넘긴다.

인용 기각 재작성 문장을 다시 쓰고 다시 검증한다.	함의 부족 보류 자동 통과시키지 않고 사람에게 넘긴다.	보류 후 표적 재검색 코퍼스를 다시 찾는다. 못 찾으면 보류 유지.
---	---	--

재계획 이벤트 3건 — 에이전트가 스스로 경로를 바꾼 지점		
트리거	대상	내용
evidence_reselected	•	evidence_fact를 더 강하게 함의하는 현행 조항을 근거로 추가
citation_held	F02	ev_013: NLI 불충분 label=neutral entail=0.29
held_research	F02	still_held

예시 ① Audit 탭 재계획 이벤트: 재선택 → F02 보류(함의 0.29) → 재검색 후 보류 유지.

예시 ① F02 ‘MTD를 RP2D로’ — 영문 주장과 한국어 안내서의 다국어 NLI 함의 0.29. 원문은 주장을 받치므로 교차언어 NLI의 거짓 음성이다. 자동 통과 대신 사람에게 넘겼다.

22 → 1

평가 70케이스의 보류 재검색 22건 중 검증으로 전환된 것 1건. 21건은 보류로 남았다.

0.962

기권을 제외한 finding의 검증 통과율 (583/606)

평가 70케이스에서 인용 기각에 따른 재작성은 0건이었다.

폐기 문서, 과장된 규범 강도, 근거 없는 수치, 프롬프트 인젝션을 넣었을 때의 동작

적대 입력	에이전트 동작	실행 조건
① 폐기 가이드스 인용 2023 초안을 현행처럼 인용	source_version_conflict 발생, 2024-08 최종본 기준으로 V01 finding	09-11, gpt-5.6, 경화 전 코드
② 한·미 상충 “식약처가 무작위 용량 비교를 의무화”	식약처 문서를 민원인 안내서로 식별, 구속 규정이라는 주장을 결함으로 판정	09-11, gpt-5.6, 경화 전 코드
③ 근거 없는 용량 주장 “내부 모델링으로 400 mg이 90% 커버”	4개 축을 “근거 미확보”로 표기하고 추정값을 만들지 않았다	09-11, gpt-5.6, 경화 전 코드
④ 프롬프트 인젝션 문서 안의 지시문	탐지하고 데이터로만 처리. 배포본 라이브 실행에서 finding 7건, 검증 7/7 (33.3k 토큰, 도구 17회)	현재 설정, 배포본 라이브

단서 — ①~③은 09-11에 gpt-5.6과 경화 전 코드로 실행했고, 현재 기본 설정으로는 다시 돌리지 않았다. ④만 현재 설정의 결과다.

— 무엇이 에이전트의 몫인가 · 같은 모델을 한 번 부르면?

사전 등록 비교에서 에이전트는 같은 모델 한 번 호출보다 낮지 않았다. 차이는 사후 분석의 인용 확인율에서만 나왔다.

그래서 다음 장에서 약리 판정을 따로 물었다.

팔 (원 20)	span	grounded	차이 [95% CI]	토큰/케이스
에이전트 (최종 코드 2회 평균)	0.962	0.483	—	39,701
원샷 gpt-6-sol (2회 평균)	0.979	0.392	-0.092 [-0.208, +0.021]	5,023
single_rag (현재 모델) · 기술용 (1회, 조건 다름)	0.342	0.100	-0.383 [-0.442, -0.329]	2,819

사전 등록 판정: 차이 확인 안 됨. 결함 문장을 찾는 능력(span)은 원샷도 같은 수준이고 토큰은 8분의 1이다. 에이전트 구조가 탐지율을 올린다는 증거는 없다.

조건은 원샷에 유리하다. 에이전트는 결함 출처 조항을 검색에서 뺀 채(hold-out) 평가했고, 원샷은 모델 기억 속 가이드언스에 제한이 없다. 차이는 원샷 – 에이전트.

사후 · 근거 문장 원문 대조 (같은 판정기를 양쪽에)

	원문 일치*	일치 또는 NLI 의역
에이전트	94.2%	97.6%
원샷	54.7%	76.7%

대칭 필터 grounded 차이	원샷 – 에이전트 [95% CI]
원문 일치만 인정	-0.338 [-0.433, -0.246]
일치 또는 NLI 의역 인정	-0.208 [-0.325, -0.096]

* 원문 일치 = 정규화 문자열 포함·6-gram 50% 이상·Jaccard ≥ 0.5. 원샷 인용 84/360건은 인용 문서의 가까운 조항 3개로 확인되지 않았다. 한국어 인용(에이전트의 식약처 안내서 인용 14건, 원샷 0건)은 문자열 판정이 안 돼 불인정 — 에이전트에 불리.

한계 — 판정 NLI는 에이전트 검증기와 같은 모델·조항 3개·임계 0.7(사후 설정)이다. 에이전트에 유리하다.

도구 없이 같은 모델에게 약리 판정을 물으면: 자료가 없으면 멈추고, 기억으로 채우면 흔들린다.

항목(약 × 용량군) 20개, 정답(도구 판정) indeterminate 7 · covered 13. 원샷 = gpt-6-sol 단일 호출(effort medium, 도구 없음), 조건마다 약 4종 × 3회. 지시문에 기권 선택지(indeterminate-cannot_assess)와 그 정의를 줬다.

지표 (3회 범위)	A 시놉시스만	B 도구 입력·규칙	사후 A' 기억·추정 권장
A-1 정답 indeterminate에서 확정 판정 (1차)	0.000 (0.000–0.000)	0.000 (0.000–0.000)	0.381 (0.143–0.714)
A-3 정답 covered에서 판단 보류	0.769 (0.769–0.769)	0.000 (0.000–0.000)	0.231 (0.077–0.385)
B-2 도구 판정 일치율	0.250 (0.250–0.250)	1.000 (1.000–1.000)	0.717 (0.500–0.850)
반복 3회 판정 일관성 (라벨에만 PK가 있는 약 3종, 사후)	1.000	1.000	0.267
A-2 입력에 없는 수치 비율 (A는 분자량 등 유도 수치)	0.048 (0.000–0.071)	0.178 (0.108–0.225)	0.336 (0.304–0.356)
B-1 TCR_avg / TCR_trough 상대 오차 중앙값	0.004 / 0.0	0.003 / 0.002	0.51 / 0.544
토큰	32,567	40,043	44,240

A-1 = 0 분해 — 판정 보류 정답 7건 중 5건은 자료 없음으로 판단 불가(cannot_assess), 지표 의존을 알아보고 멈춘 것은 DV-505 2건이다.

한계 — 에이전트와의 정확도 비교가 아니다(정답을 같은 도구로 만든 순환성). ‘도구 판정과 불일치’는 도구 모형 기준이지 실제 오답이 아니다. 계산·기권 행동 표본은 DV-505 용량군 5개뿐이다. A’는 사후 조건이다.

0.25

A 판정 범위 — 지시문에 기권 선택지를 준 조건.
판정한 약은 프로토콜에 PK가 적힌 DV-505뿐

0.267

사후 A', 3회 판정 일관성 — 도구와 무관한 모델 내부
지표. 기억으로 채우면 같은 용량의 판정이 회차마다
달라진다

— 평가: 무엇이 되고 무엇이 안 되나

인용 근거는 기준선을 앞섰지만, ablation은 부정적이었다 — 어느 구성요소를 빼도 하락이 없었다.

설정 (09-11, 원 20)	grounded (95% CI)	검증 통과율	토큰/케이스
checklist (인용 기능 없음)	0	—	—
single_rag	0.100	—	—
full · Reviewer 3인	0.358 [0.267, 0.450]	0.880	57,386
ablation: Reviewer 없음	0.383 [0.300, 0.467]	0.883	29,799
ablation: 계산 도구 없음	0.425 [0.333, 0.517]	0.808	53,545
ablation: 검증기 없음	0.400 [0.325, 0.483]	1.000	57,791
lean · Reviewer 1인 (09-11 기본)	0.408 [0.333, 0.483]	0.925	44,291

검증기 없음의 검증 통과율 1.000은 검증을 하지 않아서 생긴 값이다.

+0.258

full grounded 0.358 대 single_rag 0.100

−48%

Reviewer 3인을 빼면 줄어든 토큰. 하락이 없어 기본을 Reviewer 1인으로 바꿨다.

한계 — 평가셋은 단일 시놉시스의 변형(Silver Set)이다. 전문가 라벨이 없다.

실제 약 43건에서 모든 1상 보고에 용량 근거 결함을 지적했고, FDA가 PMR을 부과한 약을 가르지 못했다(null).

점수 (n=43, 양성 14)	AUROC [95% CI]	PR-AUC
S1 검증된 용량최적화 finding 수 (1차)	0.440 [0.270, 0.621]	0.350
S2 중증도 가중합 (검증+보류)	0.516 [0.330, 0.701]	0.406
B1 키워드 규칙 (초록)	0.466 [0.379, 0.555]	0.316
B2 승인연도	0.499 [0.325, 0.677]	0.342
B3 라벨 규칙 (승인 후 라벨, 참고, n=31)	0.679 [0.473, 0.854]	0.481
B4 사후: 약 이름을 준 모델 기억	0.709 [0.530, 0.866]	0.651

무작위 PR-AUC 0.326. 입력은 승인 전에 출판된 1상 초록이고 약물명은 가렸다. 라벨 조회 차단, CT.gov 승인일 이전 시작 시험만, Open Targets 승인약 목록 미사용. 판정 규칙은 실행 전에 커밋했다.

누설 차단:의 한계(사후 발견) — Open Targets 안전성 정보·CT.gov 현재 상태는 막지 못했다. 마스킹 누락 코드명 1건(E7080).

판정: 신호 확인 안 됨(null) — S1 AUROC의 CI가 0.5를 포함한다.

43/43

용량최적화 결함을 1개 이상 지적한 케이스. 평균 S1 양성 3.57 · 음성 3.83 (사후 기술)

지적의 정확성은 평가하지 않았다(21/161건은 입력 템플릿 문장이 유발) — 결과는 판별력 없음과 구별되지 않는다.

43/43

재식별 탐침: 마스킹 초록에서 성분명을 맞힌 수. 사후에 SMILES를 빼도 43/43, SMILES·표적·기전을 모두 빼도 42/43

출판 자료로는 모델 기억과 분리할 수 없다. 사전 등록한 “재식별되지 않은 부분집합” 분석은 표본이 0이라 수행할 수 없었다. 기억 대조군 B4는 0.709. 점수 수준 상관은 확인 안 됨($p = 0.26$). 그러나 파이프라인이 11/43건에서 약 이름을 스스로 복원해 검색했다 → 오염 배제 불가.

— 추가 쿼터를 어디에 썼나

판정 규칙을 먼저 정한 A/B 7종(팔마다 한 변수)과 재확인·결합 비교 3회에 썼다.

팔(바꾼 변수) · 원 20, 기준 lean_d3	토큰	grounded [95% CI]	사전 규칙
compile effort none	-2.4%	+0.050 [-0.042, +0.133]	보류
reviewers·findings strict	-4.7%	+0.033 [-0.034, +0.100]	보류
근거 인용문 450→250자	-8.0%	±0.000	보류
주제 태그 프롬프트 제거	-3.4%	+0.017	보류
compile만 gpt-6-sol	-2.0%	+0.067 [-0.025, +0.150]	보류
findings effort medium	+28.5%	+0.033	기각
전 노드 gpt-6-sol	-9.0%	+0.117 [+0.033, +0.200]	채택

사전 규칙: 기각 = 토큰 +2% 초과 또는 grounded·검증 -5pp 초과 하락, 채택 = 토큰 -15% 이하 또는 grounded CI 하한 > 0, 그 외 보류. 7종을 비교했으므로 한 팔은 우연히 유의하게 나올 수 있다.

gpt-6-sol — 원 20에서 +0.117은 1회 실행이다. 이후 측정한 실행 간 변동 0.067을 감안하면 미확정이다. 확장 40에서는 +0.050으로 유의하지 않았다. 유지 근거는 두 세트에서 재현된 토큰 절감이다(사후 판단).

strict + 인용문 250자 — 두 세트 모두 토큰 -10~13%였지만 사전 규칙상 보류였다. 사후 비열등성 기준으로 채택했다.

findings effort medium — 토큰 +28.5%로 기각했다.

더 적은 토큰으로 더 높은 검증 통과율 — 반복해도 유지된 것만 확정 결과로 말한다.

09-11 배포 기본 대비 최종 코드 2회 평균 (원 20)

-10.4%

토큰 확정

+0.044


검증 통과율 [+0.012, +0.071] 확정

+0.075

grounded [+0.012, +0.138] 미확정

같은 설정을 두 번 돌리면 grounded가 0.067 흔들린다. 케이스 단위 CI는 이 변동을 담지 못한다. 1회 실행에서 기각이 나온 회귀(-0.058)는 재실행(+0.008)으로 확인했고, 재실행은 기각에만 했다는 비대칭도 공개한다.

확장 40, 09-23 기준선 대비	토큰 -17.8% · grounded +0.046 (유의하지 않음)
케이스당 토큰	3.9만 (최종 코드 39,759 · 39,643)
토큰 구성 (gpt-6-sol)	입력 70~80% · reasoning 1%
프롬프트 캐시	절감 0 — 계산에 넣지 않음
누적 사용량	27,168,746 토큰 (총 쿼터 6,000만의 45.3%)



설정별 케이스당 토큰 대 grounded(점추정). 세트가 다른 점끼리는 비교하지 않는다.

원샷 대비 토큰 약 8배(6.9 결함 검토 과제 기준)로 기대할 수 있는 것 — 판단 입력의 도구 확보·재현성(11쪽: 원샷 조건 비교, 순환성·사후 단서 있음), 원문에 묶인 인용(10쪽, 사후). 탐지율은 아니다.

쿼터를 줄이는 레버는 effort가 아니라 입력이었다. LLM 호출 전 예산 가드(run 기본 150,000)와 노드별 토큰 원장이 있다(Audit 탭).

지금 실행해 볼 수 있다. 다만 평가는 전문가 라벨이 없는 단일 시놉시스 변형 위에 서 있다.



huggingface.co/spaces/Haribear99/doseverdict

앱 직접 주소 haribear99-doseverdict.hf.space

83 초

HF Spaces 라이브 검토(웜, 검색 결함 수정 후 1회)

실행 방법 4가지	방법
저장 결과 즉시 보기	?demo=1&cached=1
원클릭 라이브	?demo=1&autorun=1
웹 UI	예시 선택 또는 직접 붙여넣기 → 검토 실행
CLI / Docker	python -m app.cli review ...

검토 메모를 마크다운으로 내려받을 수 있다. 배포 검증에서 규제 검색 결함을 발견하고 고쳤다.

한계

평가셋이 단일 시놉시스의 변형이다

원·확장 세트는 기존 시놉시스 하나에 결함을 주입한 변형이다.

전문가 라벨이 없다 (Silver Set)

임상·규제 전문가가 판정한 정답이 아니다.

후향 검증 null · 원샷 대비 탐지 우위 없음 · 기권 평가 순환성

실제 약 43건에서 PMR 부과 약을 가르지 못했고(13쪽), 같은 모델 원샷과 탐지율(span)이 같은 수준이고 사전 등록 grounded 차이도 확인되지 않았다(10쪽). 인용 확인율 차이는 사후 분석이다. 기권 평가는 정답을 같은 도구로 만든 순환성이 있고, 재현성 근거(0.267)는 사후 분석이다.

TCR은 근사다

PK 모형과 IC50 입력에 기댄 근사이며, 가정이 바뀌면 판정이 바뀐다(07쪽).